

Lévy Score-Corrected Compound-Poisson

平衡采样数值实验中文总结

讨论与协作稿

2026 年 7 月

摘要

本文档面向组内讨论与协作，集中解释 Lévy score-corrected compound-Poisson (LSC-CP) 平衡采样实验的系统设置、评价指标、自由能反应坐标、终态分布误差、时间序列有效样本量、能量偏差、计算成本和数值稳定性。四个测试体系分别是一维双阱、二维四十模高斯混合、十维深度平衡 Müller-Brown 模型以及二十四维耦合 ϕ^4 模型。结果显示，稳定化 LSC-CP 在所测试步长和有限时域内显著促进了跨盆地探索，并改善了盆地占比和低维自由能面的恢复；与此同时，MoG40 的部分全局分布指标尚未达到参考底噪，实际有限步链还存在可统计分辨的能量偏差。本文档用于解释和讨论，不替代英文 manuscript-ready experiment section。

目录

1 一页式结论	3
2 研究问题、系统和实验规模	3
2.1 跳跃几何	4
3 方法和基线	4
4 指标应该怎样阅读	4
5 反应坐标、集体变量和自由能面	5
6 有限样本参考底噪 floor	6
7 终态平衡恢复：完整数值	6
7.1 双阱	7
7.2 MoG40	7
7.3 Müller-Brown 10D	7
7.4 耦合 ϕ^4 24D	8
7.5 时间方向上的松弛	9
8 Post-settling 时间序列、ESS 和偏差	9
8.1 Worst-basin ESS	10
8.2 Energy ESS 与 signed energy bias	10
8.3 偏差是否被 Monte Carlo 误差分辨	10
8.4 Split- $\hat{R}$	11
8.5 专用 H200 上的 ESS/s	11

9 LSC-CP-MA 的具体操作 11

9.1 核心思想 11

9.2 每一步的真实顺序 11

9.3 为什么必须配对 12

9.4 MA 不等于 “每步跳很多次” 13

9.5 确定性、RA 与 MA 的关系 13

9.6 有限步实现的边界 13

10 数值稳定性和诊断 14

11 参考分布及其不确定性 14

12 结果支持什么、不支持什么 14

13 当前局限性 15

14 建议的协作讨论清单 16

15 最终总结 16

1 一页式结论

体系	LSC-CP 的主要结果	与主要基线的比较	最重要的限定
双阱	盆地 TV 为 0.0036, 达到有限样本参考底噪; worst-basin ESS 为 1648。	PT 的 W_2 和 FES RMSE 更小; LSC 的 basin ESS 高于 PT。	LSC 的能量均值偏差为 +0.194, 明显大于 MCSE。
MoG40	盆地 TV 为 0.064, 达到参考带; 盆地 KL 为 0.012, 显著优于 PT 和 raw CP。	LSC 的盆地占比恢复最好; PT 的 post-settling basin ESS 更高。	$W_2 = 2.83$ 和 $MMD = 0.0482$ 仍高于参考带, 说明完整几何分布尚有残差。
MB 10D	$W_2 = 0.047$ 、TV = 0.014, 与 PT 一样达到参考底噪; worst-basin ESS 为 1952。	LSC 与 PT 基本打平: LSC 的 W_2 略小, PT 的 TV、FES RMSE 和吞吐率略优。	LSC 能量偏差 +0.039 虽数值不大, 但约为 27 个 MCSE。
耦合 ϕ^4	$W_2 = 0.100$ 、TV = 0.022、FES RMSE = 0.151, 终态误差表中整体最好。	LSC 的终态盆地恢复优于 PT; PT 的 worst-basin ESS/s 明显更高。	参考 SNIS 与长 PT 之间已有 basin TV 0.042 的差异; LSC 能量偏差为 +0.251。

表 1: 四个体系的核心结果和正确解读。

最稳妥的总结是:

在所测试的四个模型体系、步长和有限时间范围内, 稳定化 LSC-CP 实现显著促进了跨盆地探索, 并改善了盆地占比与低维自由能面的恢复; 但完整分布误差和观测量依赖的有限步偏差仍然存在。因此, 结果支持“增强平衡采样”, 不支持“实际有限步链精确无偏”。

2 研究问题、系统和实验规模

所有实验的目标都是 Boltzmann 分布

$$\pi_\beta(x) = Z_\beta^{-1} \exp[-\beta V(x)]. \quad (1)$$

研究问题不是重建物理反应动力学, 而是在强亚稳性下更快地恢复平衡分布、盆地质量和热力学观测量。

体系	d	β	粒子数	T	Δt	seeds	主要采样难点
双阱	1	8	16000	100	0.005	24	两个等深势阱之间存在 $\beta\Delta V = 8$ 的势垒, 检验两态平衡和跨阱通信。
MoG40	2	8	2500	100	0.010	24	四十个远距离等权高斯模态; 跳跃设计不使用模态位置。
深度平衡 MB	10	24	2000	200	0.005	16	二维 Müller-Brown 有效景观嵌入十维; $A \leftrightarrow B$ 势垒约为 $11.1 k_B T$ 。
耦合 ϕ^4	24	8	1000	100	0.002	16	十二个二维格点形成四个相位, 跃迁要求多体集体移动。

表 2: 实验系统和主要配置。所有体系的跳跃率均为 $\lambda = 1$ 。

2.1 跳跃几何

体系	原子数 A	跳跃 bank	设计含义
双阱	2	位于 ± 2 、径向半宽 0.2 的对称壳层	将一个势阱附近的样本直接送到另一个势阱附近。
MoG40	连续环形 law	半径均匀分布于 $[4, 15]$ ，方向在圆周上均匀	只使用典型模态间距，不使用四十个模态中心的位置。
MB	4	$A \rightarrow B$ 、 $B \rightarrow A$ 、 $B \rightarrow C$ 、 $C \rightarrow B$	只保留中继图，无直接 $A \leftrightarrow C$ 原子，要求通过中间盆地 B 。
ϕ^4	8	四相方形边上的八个有向集体原子	删除穿过场零点高能区域的两组对角跃迁；对角转换通过两个边跳中继完成。

表 3: 四个体系的跳跃设计。

3 方法和基线

方法	含义	在本文中的作用和注意事项
ULA	Unadjusted Langevin algorithm	局部过阻尼 Langevin 离散。单盆地内部混合可以很快，但跨越高势垒很慢，且有限步长会产生离散误差。
MALA	Metropolis-adjusted Langevin algorithm	用接受/拒绝校正 Langevin proposal；目标分布正确，但仍然依赖局部 proposal，跨盆地困难。
BAOAB	欠阻尼 Langevin BAOAB 积分器	带动量的局部基线。在本实验时域内仍无法覆盖所有盆地。
FLA	α -stable Lévy flight analogue	重尾长跳跃对照。它的目标不变分布不是 π_β ，因此不能把较小的某个终态误差解释为正确平衡采样。
PT	Parallel tempering	通过多个温度副本改善跨势垒通信。所有效率比较计入完整副本成本。
raw CP	只有 compound-Poisson jump，没有 Lévy-score 校正	用于检验 score 校正是否必要。其不变分布不是 π_β ，所以是 stationarity-defect 消融，而不是公平的平衡采样效率基线。
LSC-CP	Lévy-score-corrected compound-Poisson	在局部 Langevin 漂移上同时加入非局部跳跃和与该 jump law 匹配的 Lévy-score 漂移。
LSC-CP-RA	单原子随机估计器	每粒子每步只抽取一个随机位移，并在 score 与 jump 中复用；成本低但估计方差较大。
LSC-CP-MA	配对多原子随机估计器	每粒子每步为每个原子族各抽取一个位移，并在 score 与逐原子 Poisson jump 中复用同一 bank；用于 MB 和 ϕ^4 。

4 指标应该怎样阅读

指标	含义	好坏方向
W_2	样本分布与参考分布之间的 Wasserstein-2 距离。双阱中为一维精确值；高维体系在声明的低维 metric space 中计算 sliced W_2 。	越小越好
Basin TV	盆地占比总变差: $\text{TV}_{\text{basin}} = \frac{1}{2} \sum_k \hat{p}_k - p_k^* $ 。只衡量宏观盆地质量，不衡量盆地内部形状。	越小越好
Basin KL	$D_{\text{KL}}(p^* \parallel \hat{p})$ ，使用 Jeffreys 伪计数。这个方向会强烈惩罚遗漏目标盆地。	越小越好
FES RMSE	消除自由能任意加法常数后，样本自由能面与参考自由能面的加权均方根误差，单位为 $k_B T$ 。	越小越好
FES outside	样本的集体变量落在预先冻结的参考 FES 网格之外的质量。网格内部 RMSE 必须与该值一起阅读。	越小越好
MMD	由核函数定义的全局分布差异。MoG40 中它揭示了 basin population 正确但全局几何仍不完整的情况。	越小越好
IAT	积分自相关时间。时间序列相关越强，IAT 越大。	越小越好
ESS	相关样本等价于多少个独立样本，近似为 N/τ_{int} 。	越大越好，但需结合偏差
Worst-basin ESS	对每个盆地指示函数计算 ESS 后取最小值，衡量最难访问盆地的可用统计信息。	越大越好
Energy ESS	只衡量势能时间序列的去相关速度，不等价于全局盆地混合。	越大越好，但需结合 bias
Signed energy bias	轨迹平均势能减去目标平均势能。正值表示平均势能偏高，负值表示偏低。	绝对值越小越好
MCSE	Monte Carlo standard error，常用 $s/\sqrt{\text{ESS}}$ 估计。它衡量随机估计误差，不会自动消除离散核的系统偏差。	越小越好
Split- $\hat{R}$	多链一致性诊断。接近 1 表示链间与链内变化更一致；它不能验证目标分布本身正确。	越接近 1 越好
ESS/s	单位墙钟时间产生的有效样本量。只有在准确度和计费范围相当时，才能直接用于排名。	越大越好
弱恒等式残差	有限测试函数上的生成器级 drift-jump 抵消残差。它不包含 taming、cap、Euler splitting 和 box projection。	越小越好

表中括号的含义。 终态指标采用“跨 seed 均值（标准差）”格式。例如 0.064 (0.008) 表示均值为 0.064、seed 间标准差为 0.008。

5 反应坐标、集体变量和自由能面

自由能面必须相对于一个声明的集体变量

$$s = \xi(x) \quad (2)$$

来定义。该坐标上的边缘概率密度为

$$p_\xi(s) = \int \delta(s - \xi(x)) \pi_\beta(x) dx, \quad (3)$$

对应自由能

$$F_\xi(s) = -\beta^{-1} \log p_\xi(s) + C. \quad (4)$$

本文报告以 $k_B T$ 为单位的约化自由能，因此

$$\frac{F_\xi(s)}{k_B T} = -\log p_\xi(s) + C. \quad (5)$$

体系	FES 使用的 $\xi(x)$	维度	解释
双阱	$\xi(x) = x$	1	原始位置坐标，同时也是完整构型坐标。
MoG40	$\xi(x) = (x_1, x_2)$	2	完整二维构型坐标，没有额外降维。
MB 10D	$\xi(x) = (z_1, z_2)$	2	Müller-Brown 势能所在的二维 latent/active coordinates；八个高斯辅助维度被边缘化。
耦合 ϕ^4	$\xi(q) = \bar{q} = \frac{1}{12} \sum_{i=1}^{12} q_i$	2	空间平均序参量，用于区分四个相位；非均匀场涨落被投影掉。

表 6: 自由能分析使用的集体变量。

在离散网格中，第 i 个单元概率为 p_i 、单元面积或体积为 $|C_i|$ ，约化自由能为

$$A_i = -\log \frac{p_i}{|C_i|}. \quad (6)$$

由于自由能只确定到加法常数，FES RMSE 在比较前拟合一个最佳常数。只在参考概率 $p_i^* \geq 5/N$ 的 supported cells 上计算加权 RMSE；落在冻结网格外的质量单独报告为 FES outside。

术语限定。 这些坐标更准确地说用于平衡分析的集体变量或序参量，并未验证为精确 committor 或物理动力学意义上的最优反应坐标。沿这些坐标得到的自由能不能直接解释为真实反应路径或反应速率。

6 有限样本参考底噪 floor

Floor 不是理论上的严格下界，而是两个相同样本量的独立参考样本相互比较时产生的经验误差尺度。本文把

$$\text{floor band 上界} = \text{reference-reference 均值} + 3 \times \text{reference-reference 标准差} \quad (7)$$

作为“达到 floor”的判据。进入该带表示当前误差无法与有限样本参考噪声清楚区分，不表示误差严格为零，也不等价于证明收敛。

体系	W_2 floor; 上界	TV floor; 上界	LSC-CP 解读
双阱	0.061 ± 0.033 ; 0.160	0.0032 ± 0.0017 ; 0.0083	$W_2 = 0.111$ 、 $TV = 0.0036$ ，两者均进入参考带。
MoG40	1.31 ± 0.28 ; 2.15	0.051 ± 0.006 ; 0.069	$TV = 0.064$ 进入参考带； $W_2 = 2.83$ 未进入。
MB	0.050 ± 0.020 ; 0.110	0.011 ± 0.007 ; 0.032	$W_2 = 0.047$ 、 $TV = 0.014$ ，两者均进入参考带。
ϕ^4	0.130 ± 0.035 ; 0.235	0.024 ± 0.010 ; 0.054	$W_2 = 0.100$ 、 $TV = 0.022$ ，两者均进入参考带。

表 7: 有限样本 floor 及 LSC-CP 是否进入参考带。

7 终态平衡恢复：完整数值

本节所有误差指标均为越小越好。FLA 和 raw CP 不以 π_β 为不变分布，因此只能作为非目标对照或 score 消融，不能与目标正确的采样器进行无条件的效率排名。

7.1 双阱

方法	W_2	Basin TV	FES RMSE	Basin KL	Outside
ULA	1.26 (.003)	.471 (.001)	1.77 (.02)	1.09 (.02)	0
MALA	1.26 (.003)	.473 (.001)	1.79 (.02)	1.12 (.02)	0
BAOAB	1.29 (.002)	.488 (.001)	2.23 (.04)	1.54 (.04)	0
FLA	.096 (.018)	.0033 (.003)	.302 (.008)	3.4×10^{-5}	.003
PT	.064 (.032)	.0033 (.002)	.050 (.009)	3.2×10^{-5}	0
raw CP	.176 (.013)	.0036 (.003)	.157 (.006)	4.2×10^{-5}	.029
LSC-CP	.111 (.017)	.0036 (.003)	.168 (.009)	4.4×10^{-5}	.005
LSC-CP-RA	.131 (.017)	.0031 (.003)	.180 (.010)	3.2×10^{-5}	.008

表 8: 双阱终态指标, 格式为均值 (标准差)。

解释。 三种局部方法的盆地 TV 约为 0.47–0.49, 说明仍然严重偏向初始阱。PT 的全局 W_2 和 FES RMSE 最小。LSC-CP 与 RA 都恢复了左右盆地质量并进入 TV floor。raw CP 的 basin TV 看似很小, 但它的目标分布不正确, 且有 2.9% 的质量位于参考 FES 网格外。

7.2 MoG40

方法	W_2	Basin TV	FES RMSE	Basin KL	Outside
ULA	26.1 (.02)	.916 (.003)	1.81 (.01)	4.20 (.02)	0
MALA	26.1 (.03)	.917 (.003)	1.81 (.01)	4.21 (.01)	0
BAOAB	26.2 (.03)	.930 (.005)	1.77 (.01)	4.24 (.02)	0
FLA	15.2 (.21)	.436 (.007)	1.37 (.06)	.743 (.05)	.001
PT	6.54 (.34)	.141 (.007)	.350 (.02)	.055 (.005)	0
raw CP	9.98 (.19)	.286 (.009)	.680 (.04)	.267 (.013)	.254
LSC-CP	2.83 (.34)	.064 (.008)	.190 (.02)	.012 (.003)	.001
LSC-CP-RA	2.65 (.26)	.103 (.009)	.280 (.02)	.036 (.006)	.005

表 9: MoG40 终态指标, 格式为均值 (标准差)。

解释。 LSC-CP 的盆地 TV、KL 和 FES RMSE 在目标方法中最好, TV 已进入参考 floor。RA 的 $W_2 = 2.65$ 略小于确定性/半解析 LSC 的 2.83, 但其 TV、KL、FES RMSE 和 outside 均更差。因此 RA 只能作为估计器敏感性检查, 不能称为与确定性 score 数值等价。最重要的负结果是: LSC 的 $W_2 = 2.83$ 高于 floor 上界 2.15, $MMD = 0.0482$ 也高于参考带上界约 0.0317。这说明四十个模态的质量已经接近正确, 但完整全局几何分布仍有残差。raw CP 有 25.4% 的质量落在参考 FES 网格外, 而 LSC 只有 0.1%。

7.3 Müller–Brown 10D

方法	W_2	Basin TV	FES RMSE	Basin KL	Outside
ULA	.409 (.003)	.307 (.002)	2.27 (.23)	1.17 (.14)	0
MALA	.411 (.003)	.308 (.001)	2.32 (.18)	1.22 (.16)	0
BAOAB	.415 (.003)	.309 (.001)	2.50 (.17)	1.52 (.21)	0
FLA	.179 (.006)	.119 (.008)	.941 (.04)	.048 (.007)	.039
PT	.056 (.021)	.013 (.008)	.132 (.02)	5.7×10^{-4}	0
raw CP	.353 (.008)	.135 (.006)	.267 (.02)	.047 (.005)	.172
LSC-CP-MA	.047 (.009)	.014 (.006)	.136 (.010)	5.8×10^{-4}	.006

表 10: 深度平衡 MB 10D 终态指标, 格式为均值 (标准差)。

解释。 PT 和 LSC-CP-MA 的 W_2 、TV、FES RMSE 和 KL 基本打平，并且 W_2 与 TV 都进入参考底噪。LSC 的 W_2 略小；PT 的 TV、FES RMSE 和 KL 略小。raw CP 有 17.2% 的样本质量位于参考网格外，LSC 为 0.6%。

7.4 耦合 ϕ^4 24D

方法	W_2	Basin TV	FES RMSE	Basin KL	Outside
ULA	1.22 (.004)	.671 (.003)	2.59 (.09)	3.07 (.31)	0
MALA	1.22 (.004)	.673 (.002)	2.63 (.05)	3.13 (.17)	0
BAOAB	1.22 (.006)	.673 (.002)	2.64 (.05)	3.14 (.22)	0
FLA	.194 (.032)	.060 (.013)	.220 (.03)	.011 (.004)	10^{-4}
PT	.364 (.028)	.119 (.015)	.315 (.04)	.039 (.008)	0
raw CP	.410 (.021)	.077 (.016)	.482 (.05)	.017 (.006)	.209
LSC-CP-MA	.100 (.028)	.022 (.011)	.151 (.03)	.0015 (.001)	.003

表 11: 耦合 ϕ^4 24D 终态指标，格式为均值（标准差）。

解释。 LSC-CP-MA 在该表的五个终态指标上均最好，并且 W_2 与 TV 均进入参考底噪。raw CP 的网格外质量为 20.9%，LSC 为 0.3%。FLA 的若干数字看似有竞争力，但它并不以 π_β 为不变分布。 ϕ^4 的 SNIS 参考与独立长 PT 参考之间已有 basin TV = 0.042 的差异，因此小于这一尺度的盆地优劣具有参考敏感性。

7.5 时间方向上的松弛




图 1: 从共同局域初始分布出发, W_2 随算法时间的变化。上排: 双阱、MoG40; 下排: MB 10D、耦合 ϕ^4 。这些曲线显示非局部方法能够降低全局分布误差, 而局部方法在给定域内仍强烈亚稳。

8 Post-settling 时间序列、ESS 和偏差

终态 ensemble 指标衡量时刻 T 的分布误差, 不直接给出时间平均的精度。时间序列实验使用 4 个 seed、每个 seed 8 条链、每条链 1000 个等间隔记录, 总计 32000 个 post-settling 样本。链从参考分布初始化, 先演化一个 settling horizon, 再记录一个 horizon。raw CP 和 FLA 因目标不变分布不是 π_β , 未纳入该效率表。

8.1 Worst-basin ESS

方法	双阱	MoG40	MB	ϕ^4
ULA	0	0	0	0
MALA	0	0	0	0
BAOAB	0	0	0	0
PT	1211	572	2336	2567
LSC-CP	1648	229	1952	1150
LSC-CP-RA	1809	59	—	—

表 12: Worst-basin ESS，总记录量为 32000。越高表示最难采样盆地的占比时间序列包含越多近似独立信息。

局部方法的 worst-basin ESS 全为零，说明至少有一个盆地指示函数恒定或没有被有效访问。这不等于完全没有 label change：MoG40 中 ULA/MALA/BAOAB 分别记录 222/230/60 次变化，MB 中为 209/194/43 次，但这些变化不足以覆盖全部盆地并形成可用的最慢盆地统计量。LSC 在四个体系中均获得非零 worst-basin ESS。双阱中 LSC 高于 PT；MoG40、MB 和 ϕ^4 中 PT 更高。

8.2 Energy ESS 与 signed energy bias

方法	双阱: ESS / bias	MoG40: ESS / bias	MB: ESS / bias	ϕ^4 : ESS / bias
ULA	14815/ + 0.0003	707/ + 0.001	22223/ + 0.007	17212/ + 0.133
MALA	14869/ + 0.0005	710/ - 0.004	21994/ - 0.001	15250/ - 0.010
BAOAB	3658/ - 0.0002	534/ - 0.001	5622/ + 0.004	2734/ + 0.028
PT	20494/ - 0.001	1340/ + 0.0006	25202/ - 0.0004	24383/ - 0.002
LSC-CP	31891/ + 0.194	22718/ + 0.114	26720/ + 0.039	30972/ + 0.251
LSC-CP-RA	31224/ + 0.247	9165/ + 0.448	—	—

表 13: 能量 ESS 与带符号能量偏差。ESS 越高只表示能量去相关快；bias 的绝对值越小才表示能量均值更准确。

这张表说明 ESS 不能单独使用。LSC 的 energy ESS 很高，但能量均值存在明确正偏。另一个典型反例是 MB 中 ULA 的 energy ESS 为 22223，而 worst-basin ESS 为零：粒子可以在单个盆地内部快速改变势能，却没有完成全局混合。

8.3 偏差是否被 Monte Carlo 误差分辨

体系	LSC energy bias	MCSE	bias /MCSE
双阱	+0.194	0.0194	10.0
MoG40	+0.114	0.00485	23.5
MB	+0.039	0.00143	27.3
ϕ^4	+0.251	0.0141	17.8

表 14: LSC-CP 能量偏差与 Monte Carlo standard error。

所有偏差都远大于 MCSE，因此不是普通抽样波动，而是当前样本量能够清楚分辨的系统偏差。增加轨迹长度会缩小 MCSE，但不会自动消除由有限步长、有限求积、taming、score cap 或 box projection 造成的离散核偏差。RA 的对应比值约为：双阱 9.0，MoG40 27.3。

8.4 Split- $\hat{R}$

能量的 split- $\hat{R}$ 在表中方法上均小于 1.11，但其他盆地和集体变量并非如此：

方法/体系	最大 split- $\hat{R}$
MoG40 LSC-CP	1.70
MoG40 LSC-CP-RA	1.61
MoG40 PT	1.28
ϕ^4 PT	1.13

表 15: 部分方法在所有观测量上的最大 split- $\hat{R}$ 。

这些值表明并非每个盆地或 collective-variable trace 都已达到良好多链一致性。 $\hat{R}$ 也不能验证目标分布本身正确：多条链可能一致地采样同一个有偏离散分布。

8.5 专用 H200 上的 ESS/s

只有 MB 与 ϕ^4 在无并发 GPU 负载下报告每秒效率。

体系	指标	LSC-CP	PT	比较
MB	Energy ESS/s	33.03	48.23	PT 约为 1.46×
MB	Worst-basin ESS/s	2.41	4.47	PT 约为 1.85×
ϕ^4	Energy ESS/s	50.80	62.17	PT 约为 1.22×
ϕ^4	Worst-basin ESS/s	1.89	6.55	PT 约为 3.47×

表 16: 专用单张 H200 GPU 上的吞吐率。PT 计入全部温度副本成本。

在这两个体系的墙钟吞吐率上，PT 更高，尤其 ϕ^4 的跨盆地吞吐率优势明显。另一方面，LSC 在报告时点的部分 terminal population 指标更准确。因此应联合阅读终态误差、时间序列 ESS、观测量偏差和计算成本，不能用单一数字宣布统一赢家。

9 LSC-CP-MA 的具体操作

9.1 核心理想

对预先定义的 A 个原子族 $\{r_a, w_a, q_a\}_{a=1}^A$ ，LSC-CP-MA 在每个粒子、每个时间步独立刷新一个多原子随机 bank。对粒子 i ,

$$R_{i,a} \sim q_a, \quad a = 1, \dots, A, \quad (8)$$

并定义粒子特异的随机有限测度

$$\hat{\nu}_i(dr) = \lambda \sum_{a=1}^A w_a \delta_{R_{i,a}}(dr). \quad (9)$$

同一个 realized bank 同时用于计算 Lévy-score 漂移和生成逐原子的 Poisson jump。不同粒子不共享 realized bank；所有粒子只共享确定性原子中心、权重和壳层宽度。

9.2 每一步的真实顺序

1. 抽取随机 bank。对每个粒子和每个原子族，

$$\rho_{i,a} \sim \text{Unif}(-h_a, h_a), \quad R_{i,a} = r_a + \rho_{i,a} \frac{r_a}{\|r_a\|}. \quad (10)$$

生产实验的 Gaussian jitter 为零。bank 张量形状为 (N, A, d) ，抽样函数没有状态参数，因此 bank 在结构上独立于当前 X_n 。

2. 抽取逐原子 Poisson 次数。

$$N_{i,a} \sim \text{Poisson}(\lambda w_a \Delta t), \quad \Delta J_i = \sum_a N_{i,a} R_{i,a}. \quad (11)$$

MA 模式不截断 count。若某个 $N_{i,a} > 1$ ，该步内的多次事件复用同一个 $R_{i,a}$ 。总期望跳跃数仍为

$$\sum_a \mathbb{E}[N_{i,a}] = \lambda \Delta t. \quad (12)$$

3. 用同一个 bank 计算 score。 对每个原子和 Gauss-Legendre 节点，

$$I_{i,a}(X_n) \approx \sum_{p=1}^{q_\theta} \omega_p \exp\{\beta [V(X_n) - V(X_n - \theta_p R_{i,a})]\}, \quad (13)$$

然后

$$S_{\mathcal{R}_i, \beta}(X_n) = -\lambda \sum_{a=1}^A w_a R_{i,a} I_{i,a}(X_n). \quad (14)$$

实现使用 log-sum-exp，并在所有原子完成相对加权之后，对每个粒子的总 log-magnitude 使用 $M_{\max} = 600$ 的 cap。这样在 cap 触发时仍保留原子间相对贡献和合成方向，只改变总幅度。

4. 组成总漂移并进行 tamed Euler 更新。

$$b_n = -\nabla V(X_n) + S_{\mathcal{R}_i, \beta}(X_n), \quad (15)$$

$$X_n^{\text{pre}} = X_n + \Delta t \frac{b_n}{1 + \Delta t \|b_n\|/c} + \sqrt{\frac{2\Delta t}{\beta}} \xi_n, \quad \xi_n \sim N(0, I). \quad (16)$$

MB 和 ϕ^4 使用

$$h = 0.1 \min_a \|r_a\|, \quad c = 2h. \quad (17)$$

因此大漂移极限下，单步漂移位移长度趋于 c 。

5. 施加 jump 并投影。

$$X_{n+1}^{\text{raw}} = X_n^{\text{pre}} + \sum_a N_{i,a} R_{i,a}, \quad X_{n+1} = \text{clip}_{\mathcal{B}}(X_{n+1}^{\text{raw}}). \quad (18)$$

即使该步所有 $N_{i,a} = 0$ ，score 漂移仍然作用。score 不是只在 jump 发生时启动的事后修正。

9.3 为什么必须配对

冻结 realized bank 后，score 和 jump 都对应同一个测度 $\hat{\nu}_i$ 。在精确弦积分和连续生成器层面，漂移项和 jump 项可以逐原子满足弱抵消。再对随机 bank 取平均有

$$\mathbb{E}[\hat{\nu}_i] = \nu. \quad (19)$$

如果 score 使用 bank $\mathcal{R}$ ，jump 却独立使用另一个 bank $\mathcal{R}'$ ，即使 score 在边缘平均意义下无偏，每一步的条件 drift-jump 测度仍然失配。

9.4 MA 不等于“每步跳很多次”

体系	A	q_θ	每原子 Poisson 均值	每粒子每步 score 能量差数
MB	4	8	0.00125	$4 \times 8 = 32$
ϕ^4	8	32	0.00025	$8 \times 32 = 256$

表 17: LSC-CP-MA 的 bank 大小、跳跃稀疏度和 score 成本。

MA 的“multi-atom”表示每一步的 score 对每个原子族都有一个随机代表。真正的 jump 仍然非常稀疏：MB 每粒子每步总期望 jump 数为 0.005， ϕ^4 为 0.002。

9.5 确定性、RA 与 MA 的关系

版本	每粒子每步处理的 jump law	score 成本	特点
确定性 score	对原子、径向节点和弦节点做确定性求积	$Aq_\rho q_\theta$	随机估计方差低，但高维计算昂贵。
RA	从完整 mixture 中只抽一个位移 R	q_θ	最便宜，但在 MoG40 上 basin ESS 和 KL 对随机估计更敏感。
MA	每个原子族各抽一个 R_a ，按 w_a 分层加权	Aq_θ	覆盖全部跳跃类型，方差和成本介于 RA 与完整确定性求积之间。

表 18: 三种 score 实现的比较。配置表中的 q_ρ 不参与 MA 的逐步 realized-bank score；MA 直接从连续径向壳层抽取 $\rho_{i,a\circ}$

9.6 有限步实现的边界

配对结构保证的是给定 realized bank 时 score 与 jump 使用同一测度。它不自动证明实际有限步链精确保持 π_β ，因为实现还包含：

- 有限 q_θ 弦积分；
- score log-magnitude cap；
- Euler drift/diffusion–jump splitting；
- 总漂移 taming；
- 有限状态盒 projection；
- 同一原子单步多次事件复用同一个 realized displacement。

因此，MA 应被表述为“消除 score 与 jump 使用不同随机 bank 的额外失配”，而不是“使稳定化有限步链精确无偏”。

10 数值稳定性和诊断

诊断量	双阱	MoG40	MB	ϕ^4
非有限状态数	0	0	0	0
LSC score-cap 比例	5.02×10^{-4}	0	2.85×10^{-7}	2.09×10^{-4}
状态盒投影比例, 各方法最大值	8.67×10^{-5}	3.84×10^{-4}	3.304×10^{-3}	8.903×10^{-4}
LSC jump 边界接触率	1.69×10^{-4}	1.05×10^{-5}	2.18×10^{-3}	1.60×10^{-4}
raw CP jump 边界接触率	3.03×10^{-4}	2.475×10^{-2}	6.733×10^{-2}	4.130×10^{-3}
目标方法盆地映射域逃逸	0	0	0	1.0×10^{-3}
未截帽弱恒等式残差	1.5×10^{-7}	3.0×10^{-8}	5.0×10^{-7}	2.0×10^{-7}

表 19: 数值稳定性诊断。比例通常越低越好。

- 四个体系的 nonfinite count 均为零, 说明稳定化成功避免了 NaN/Inf 爆炸。
- 正常轨迹上的 score cap 和 box projection 比例较低, 但任何非零触发都会改变转移核; 低频只支持数值稳健性, 不证明精确平稳。
- 在故意扩展的弱恒等式诊断网格上, 双阱和 MB 的 cap 前指数超阈值比例分别为 0.402 和 0.374; 这与真实轨迹上的 activation fraction 不是同一个量。
- raw CP 在 MoG40 和 MB 上的 jump 边界接触率分别为 2.475% 和 6.733%, 因此有限盒显著混杂了 raw-CP 消融, 不能把全部差异都归因于缺少 score。
- ϕ^4 的 basin-map escape 10^{-3} 对应一个粒子在一个 checkpoint 越界, 不是持续的千分之一稳态概率。
- 所有弱恒等式残差均低于 10^{-6} , 但它只检查未截帽、求积定义的生成器级 drift-jump 抵消。

11 参考分布及其不确定性

体系	参考构造	需要注意的地方
双阱	指定有限盒上的 2×10^5 点稠密网格逆 CDF	一维参考精度高, 但仍以声明的有限盒为定义域。
MoG40	直接从已知等权 Gaussian mixture 精确抽样	四个体系中最直接的参考。
MB	2400^2 二维 latent 网格乘以精确高斯辅助坐标	FES、盆地质量和低维 metric space 主要由二维 latent 坐标定义。
ϕ^4	四个相位极小点上的 Laplace mixture proposal, 加 self-normalized importance weights	参考是近似的; 必须结合权重 ESS 和独立 PT cross-check 阅读。

表 20: 四个体系的参考分布。

ϕ^4 参考使用 2×10^5 个 proposal, 权重 ESS 为 41182, 即 20.6%, 最大归一化权重为 3.6×10^{-3} 。盆地质量、能量矩、集体变量均值和 FES 直接使用 SNIS 权重; 只有 W_2 、MMD 等要求无权样本的指标才使用有限 sampling-importance-resampling。独立长 PT 得到的相位质量与 SNIS 参考之间的 basin TV 为 0.042, 因此低于这一尺度的 ϕ^4 盆地差异具有参考敏感性。

12 结果支持什么、不支持什么

陈述	是否支持	原因
局部方法在给定时域内无法完成全局盆地混合。	支持	四个体系的 worst-basin ESS 均为零，终态 basin TV/KL 很大。
LSC-CP 显著改善跨盆地探索和盆地占比恢复。	支持	四个体系的 LSC worst-basin ESS 均非零，终态 basin TV 显著小于局部方法。
Lévy-score 校正显著减轻 raw jump 的分布失真。	支持但有限定	MoG40、MB、 ϕ^4 的 outside mass 大幅下降；但 raw CP 受有限盒边界混杂。
LSC-CP 在所有指标和成本口径上优于 PT。	不支持	PT 在部分体系的 basin ESS、ESS/s 和部分 FES 指标上更优。
LSC-CP 在所有体系的完整分布指标上都达到 floor。	不支持	MoG40 的 W_2 和 MMD 仍高于参考带。
稳定化成功避免数值爆炸。	支持	四个体系的 nonfinite count 均为零，cap/projection 激活总体较低。
稳定化有限步链对所有热力学观测量严格无偏。	不支持	LSC 的能量偏差为 +0.039 至 +0.251，并被 MCSE 清楚分辨。
弱恒等式残差低于 10^{-6} 证明实际链精确平稳。	不支持	该残差不包含 finite- Δt 、taming、cap 和 projection。
较高 energy ESS 证明全局混合良好。	不支持	局部方法可以有很高 energy ESS，同时 worst-basin ESS 为零。
RA 与确定性 score 数值等价，并验证了 MA。	不支持	MoG40 的 RA basin KL 约为确定性 LSC 的三倍；RA 只能作为敏感性检查。
Passage time 或 round-trip time 是物理反应时间。	不支持	跳跃 bank、score drift 和算法时钟均为平衡采样设计，不是物理动力学。
收益已被证明来自设计的 jump geometry。	尚未支持	当前缺少长度、权重、原子数、跳跃率和成本匹配的随机方向几何消融。

13 当前局限性

1. 理论弱平稳性属于理想连续时间、精确未截帽的生成器；实际算法包含有限求积、Euler splitting、taming、指数 cap 和有限盒 projection。
2. MoG40 的 basin population 已接近参考，但 W_2 和 MMD 仍显示全局几何残差。
3. LSC 链存在可统计分辨的能量偏差；需要系统的 Δt 、 q_θ 、taming、cap 和 box 消融来分离来源。
4. 当前没有 matched-length random-geometry control，不能严格区分“设计几何”与“任何长跳跃”的贡献。raw CP 只消融 score，不消融 geometry。

5. ϕ^4 的 box sensitivity 只检查过一次 $L = 2 \rightarrow 5$; 还不能声称一般的 box-size independence。
6. ϕ^4 参考的 SNIS 与长 PT 已相差 basin TV 0.042; 小差异不可过度解释。
7. MB 与 ϕ^4 的 FES 和 W_2 主要位于低维 collective-variable space, 不能单独证明完整高维构型分布已经恢复。
8. 四个体系仍是模型问题, 当前结果不能自动推广到真实分子体系或物理动力学。

14 建议的协作讨论清单

优先级	讨论问题	建议的下一步
高	有限步能量偏差来自哪里?	对 Δt 、taming cap c 、 $M_{\max}$ 、 q_θ 和 box size 分别做单因素 refinement; 同时报告 population error 与 energy bias。
高	设计 jump geometry 是否真的优于通用长跳跃?	加入 matched-length random-geometry control: 匹配原子数、长度多重集、权重、率和 score 成本, 只随机化方向。
高	自由能和低维指标是否足够代表高维分布?	在 MB 的辅助维度和 ϕ^4 的非均匀场模上加入额外 observables, 例如方差、相关函数和若干高维投影。
高	ϕ^4 参考是否足够稳定?	增加独立参考或更长 PT/SNIS 交叉检查; 将 0.042 的参考差异传播到结果表述。
中	MA 与确定性 score 的差异有多大?	在可承受的小规模配置上直接比较 deterministic、RA、MA, 并分别扫描 q_θ 与 bank 刷新方差。
中	LSC 与 PT 应怎样进行公平成本比较?	统一报告 ESS/s、ESS/gradient、ESS/potential、ESS/score-quadrature, 并明确 PT 的全副本成本。
中	反应坐标是否需要更强的动力学解释?	如果只讨论平衡 FES, 统一使用 collective variable/order parameter; 只有验证 committor 后才称为物理 reaction coordinate。

表 22: 建议用于组内协作的讨论与实验补全清单。

15 最终总结

1. LSC-CP 的最清楚收益是跨盆地 equilibrium exploration: 局部方法在四个系统上 worst-basin ESS 为零, 而 LSC 在所有系统上均为非零。
2. 盆地质量恢复与完整分布恢复不是同一件事。MoG40 明确展示了 TV 到达 floor, 但 W_2 和 MMD 仍高于参考带。
3. MA 通过“每粒子、每步、多原子 bank, 并在 score 与 jump 中复用”减少随机测度失配; 它不意味着每步发生多个 jump, 也不意味着有限步链精确无偏。
4. 数值稳定化是必要且有效的: 四个体系均无 NaN/Inf; 但 energy bias 表明 finite-step equilibrium error 必须作为结果的一部分报告。
5. PT 在部分 ESS 和吞吐率口径上更优, LSC 在部分终态 population 指标上更准。选择方法应取决于关心的 observable 和成本口径。
6. 当前最重要的后续工作是 matched random-geometry control、有限步 bias refinement、 ϕ^4 参考强化以及高维 observables 补充。

综合盆地误差、投影分布误差、时间序列 ESS、能量偏差和计算成本, 当前结果表明 LSC-CP 是一种有前景的稳定化非局部平衡采样方法; 其有限步偏差、跳跃几何贡献和真实分子体系适用性仍需进一步消融与验证。